

Návrh riešenia
Interný AI asistent
V4

RNDr. Marek Matonok

1 Manažérske zhrnutie

Navrhujem hybridnú Azure-native architektúru interného AI asistenta založenú na RAG, deterministickej autorizácii mimo LLM, permission-aware retrievale, model routingu, guardrails, audite a human-in-the-loop. Prvá verzia má overiť hodnotu na nízko rizikových dokumentových a analytických scenároch. Cieľový stav má umožniť rozšírenie na ďalšie interné zdroje, nástroje a citlivejšie use cases až po overení bezpečnosti, kvality odpovedí a governance procesov.

Hlavné rozhodnutia: použiť RAG namiesto plošného fine-tuningu, vynútiť autorizáciu mimo LLM, zaviesť hybridný model routing a začať obmedzeným MVP rozsahom s Go/No-Go vyhodnotením.

2 Východiská a pracovné predpoklady

Organizácia plánuje zaviesť interného AI asistenta, ktorý bude podporovať zamestnancov pri práci s internými informáciami, procesmi a analytickými činnosťami. Riešenie má pomáhať najmä pri vyhľadávaní interných smerníc, sumarizácii informácií, príprave návrhov odpovedí, analýze požiadaviek z biznisu, návrhu user stories a identifikácii dopadov, závislostí a rizík.

Základný princíp riešenia je, že AI asistent nemá automaticky rozhodovať za používateľa. Má poskytovať odporúčania, návrhy a pracovné podklady, ktoré používateľ vie overiť, upraviť a schváliť.

2.1 Pracovné hypotézy a predpoklady

Pri návrhu interného AI asistenta vychádzam z nasledujúcich pracovných hypotéz a predpokladov. Tieto predpoklady slúžia na spresnenie rozsahu riešenia, architektúry, bezpečnostného modelu a roadmapy.

2.1.1 Používatelia budú mať rozdielne prístupové práva

Predpokladám, že nie všetci zamestnanci majú rovnaký prístup k interným dokumentom, projektom, dátam alebo systémom. Riešenie preto musí rešpektovať existujúce oprávnenia používateľa a aplikovať autorizáciu pred vyhľadávaním dokumentov, pred volaním toolov a pri prístupe k downstream systémom. AI model nesmie byť komponent, ktorý rozhoduje o tom, či používateľ môže vidieť konkrétny obsah.

2.1.2 Dokumenty budú mať rôznu kvalitu, aktuálnosť a klasifikáciu

Predpokladám, že interné dokumenty nebudú homogénne. Niektoré môžu byť zastarané, duplicitné, neúplné, bez jasného vlastníka alebo bez explicitnej klasifikácie citlivosti. Preto musí byť súčasťou riešenia proces správy znalostnej bázy, verzionovania, označovania vlastníkov dokumentov, klasifikácie dát a validácie zdrojov.

2.1.3 Bezpečnostný model bude založený na princípe least privilege

Predpokladám, že AI asistent a jeho integračné komponenty budú mať len minimálne potrebné oprávnenia. Pri práci s dokumentmi a nástrojmi sa nemá používať vysoko privilegovaný účet ani service-to-service prístup bez dodatočných kontrol. Preferovaný model je delegovaný prístup používateľa (On-Behalf-Of princíp).

2.1.4 Primárnym zdrojom znalostí budú interné dokumenty a systémy organizácie

Predpokladám, že hlavná hodnota riešenia bude založená na schopnosti pracovať s internými smernicami, metodikami, procesmi, projektovou dokumentáciou, požiadavkami, backlogmi a znalosťami uloženými v existujúcich firemných systémoch. AI asistent preto nebude len všeobecný chatbot, ale enterprise knowledge assistant napojený na interné zdroje cez riadený RAG prístup.

2.1.5 Riešenie bude využívať RAG namiesto plošného dotrénovania modelu

Predpokladám, že pre prvé fázy riešenia bude vhodnejší Retrieval-Augmented Generation prístup než rozsiahle fine-tuning alebo tréning vlastného modelu.

2.1.6 Externí enterprise AI asistenti môžu byť použítí, ale len za presne definovaných podmienok

Predpokladám, že niektoré use cases môžu vyžadovať vyššiu kvalitu reasoning modelov alebo väčší kontext, než poskytujú lokálne modely v kombinácii s interným asistentom. Preto môže byť vhodný hybridný model využitia AI služieb.

2.1.7 Kvalita odpovedí bude meraná a priebežne zlepšovaná na základe spätnej väzby používateľov.

Predpokladám, že úspech riešenia nebude hodnotený len technickým nasadením, ale aj kvalitou odpovedí, mierou použiteľnosti, spokojnosťou používateľov, presnosťou citácií, počtom halucinácií, časovou úsporou a mierou používateľskej adopcie. Súčasťou riešenia preto musí byť spätná väzba, audit, testovanie promptov, porovnanie s referenčnými odpoveďami a pozitívny aj negatívny feedback od používateľov.

2.1.8 Regulačné a compliance požiadavky budú významným obmedzením

Predpokladám, že riešenie bude musieť rešpektovať interné bezpečnostné politiky, ochranu osobných údajov, pravidiel správy dokumentácie a auditné požiadavky. Preto bude potrebné zahrnúť logovanie s minimalizáciou dát, retenčné politiky a jasné vlastníctvo rizík.

2.1.9 Ochrana osobných údajov a súkromia

AI asistent nemá pracovať s osobnými údajmi, ak to nie je potrebné. Ak osobné údaje potrebuje, má ich spracovať len v minimálnom rozsahu. Citlivé údaje sa majú maskovať, anonymizovať alebo redigovať. Iba používatelia s oprávnením budú mať prístup k toolom s týmito údajmi.

3 Návrh riešenia

3.1 Cieľ riešenia

Cieľom navrhovaného riešenia je vytvoriť bezpečného interného AI asistenta pre zamestnancov organizácie, ktorý bude podporovať prácu s internými znalosťami, metodikami, procesmi a biznis požiadavkami. Asistent má znížiť čas potrebný na hľadanie informácií, zvýšiť konzistentnosť analytických výstupov a pomôcť tímom pripravovať kvalitnejšie podklady pre rozhodovanie.

Systém nebude odpovedať iba zo všeobecných znalostí, t. j. z cutoff knowledge modelu, na ktorom bol trébovaný, ale bude odpovede pripravovať na základe interných dokumentov a znalostí organizácie.

Hlavným zámerom nie je automatizovať rozhodovanie, ale zvýšiť produktivitu, kvalitu a transparentnosť práce. AI asistent má poskytovať návrhy, odporúčania, sumarizácie a analytické výstupy, ktoré používateľ overí a následne použije podľa interných pravidiel organizácie.

3.1.1 Merateľné ciele prvej verzie

Cieľ	Popis	Príklad metriky
Konzistentnejšie analytické výstupy	Asistent používa jednotné šablóny pre user stories, akceptačné kritériá, riziká a otvorené otázky.	Podiel výstupov vytvorených podľa šablóny.
Vyššia transparentnosť	Odpovede obsahujú použité zdroje, limitácie a upozornenia na neistotu.	Podiel odpovedí so zdrojmi a groundedness skóre.
Bezpečné používanie AI	Autorizácia je vynútená mimo LLM a citlivé dáta sú spracované podľa pravidiel klasifikácie, GDPR, DLP	Počet policy violation udalostí a výsledky auditov.

3.2 Hlavné use cases

Prvá verzia riešenia by sa mala zamerať na use cases s vysokou frekvenciou, jasnou biznis hodnotou a kontrolovateľným rizikom. Preto je pre overenie systému vo V1 a monitorovanie merateľnosti vhodný scenár vyhľadávania z verejných zdrojov organizácie. Ďalšie, nižšie uvedené scenáre sa budú postupne pripravovať v nasledujúcich verziách.

Use case	Opis	Typický výstup
Vyhľadávanie z verejných zdrojov organizácie	Používateľ položí otázku v prirodzenom jazyku. Asistent vyhľadá relevantné dokumenty, ktoré používateľ smie vidieť, a pripraví odpoveď so zdrojmi. Orientácia na verejne dostupné zdroje organizácie.	Stručná odpoveď, odkaz na zdroj, citovaná sekcia, limitácie Výstup vo semi štruktúrovanom formáte pre ďalšie spracovanie AI asistentom.
Analýza biznis požiadaviek	Asistent rozoberie požiadavku, identifikuje nejasnosti, dopady, závislosti a otázky pre biznis alebo technické tímy.	Analytický rozpad, predpoklady, riziká, ďalšie kroky.
Vyhľadávanie v interných smerniciach	Používateľ položí otázku v prirodzenom jazyku. Asistent vyhľadá relevantné dokumenty, ktoré používateľ smie vidieť, a pripraví odpoveď so zdrojmi.	Stručná odpoveď, odkaz na zdroj, citovaná sekcia, limitácie.
Sumarizácia dokumentov	Používateľ nahrá alebo vyberie dokument, ktorý asistent spracuje do štruktúrovaného zhrnutia.	Krátke a detailné zhrnutie, rozhodnutia, riziká, otvorené otázky.
Príprava návrhov odpovedí	Asistent vytvorí návrh odpovede na interný e-mail, ticket alebo požiadavku. Výstup je označený ako návrh.	Návrh odpovede, argumentácia, zdroje, upozornenia.
Návrh user stories	Asistent pripraví návrh user stories, akceptačných kritérií, edge cases a nefunkčných požiadaviek.	User stories, acceptance criteria, otvorené otázky.
Identifikácia dopadov a rizík	Asistent pomôže odhadnúť dotknuté systémy, procesy, dátové závislosti a možné prevádzkové alebo bezpečnostné riziká.	Dopadová mapa, riziká, závislosti, odporúčané overenia.

3.3 Cieľoví používatelia

Primárnymi používateľmi budú zamestnanci, ktorí pracujú s internými znalosťami, procesmi, dokumentáciou alebo požiadavkami. Riešenie má byť použiteľné pre bežných zamestnancov aj špecializované role, pričom výstupy a dostupné nástroje sa budú líšiť podľa oprávnení a pracovného kontextu.

Skupina používateľov	Typické potreby
Biznis analytici	Analýza požiadaviek, otázky na biznis, user stories, akceptačné kritériá, identifikácia otvorených bodov.
Product owneri	Príprava backlogu, prioritizácia, dopady, komunikácia so stakeholdermi a tímami.
Solution / enterprise architekti	Dopadová analýza, závislosti, architektonické odporúčania, posúdenie rizík.
Projektoví manažéri	Sumarizácie zápisov, rozhodnutia, riziká, ďalšie kroky a stavové podklady.
Vývojové a agilné tímy	Pochopenie požiadaviek, návrhy taskov, technické dopady, kontext k backlogu.
Compliance / risk / security tímy	Overenie súladu s internými pravidlami, kontrola rizík a bezpečnostných dopadov.
Bežní zamestnanci	Vyhľadávanie interných smerníc, postupov, metódik a praktických odpovedí, vyhľadávanie z verejných zdrojov organizácie.

3.4 Administrátorské a podporné roly, tímy

Rola	Zodpovednosť
AI Product Owner	Definuje backlog, priority, hodnotu riešenia a akceptačné kritériá.
AI/Solution/Enterprise Architect	Navrhuje architektúru, integrácie, bezpečnostné princípy a technologické rozhodnutia.
Data Owner	Zodpovedá za kvalitu, aktuálnosť a oprávnenia k dokumentom a znalostným zdrojom.
Security Officer	Definuje bezpečnostné požiadavky, kontrolné mechanizmy a pravidiel pre citlivé dáta.
Platform / Cloud tím	Prevádzkuje Azure infraštruktúru, monitoring, networking a nasadenie.
AI Governance Board	Schvaľuje pravidlá, riziká, výnimky, modelové politiky a produkčné použitie.

3.5 Hranice riešenia

Riešenie je navrhnuté ako interný AI asistent, nie ako autonómny rozhodovací systém. Hranice riešenia musia byť jasne komunikované používateľom aj prevádzkovým tímom. Najmä platí, že AI môže pripravovať návrhy a odporúčania, ale **záväzné rozhodnutia a schvaľovanie zostávajú na zodpovedných osobách a existujúcich governance procesoch**.

Súčasť prvej verzie	Mimo rozsahu prvej verzie
Chatové používateľské rozhranie v Teams alebo internom portáli.	Plne autonómne schvaľovanie zmien alebo rozhodovanie za používateľa.
Napojenie na vybrané interné dokumenty a znalostné zdroje.	Automatické vykonávanie akcií v produkčných systémoch bez explicitného schválenia.
RAG nad internými dokumentmi s permission-aware retrievalom.	Automatické právne, finančné, HR alebo bezpečnostné stanoviská bez validácie oprávnenou osobou.
Návrhy odpovedí, sumarizácií, user stories a analytických výstupov.	Prístup k dokumentom bez rešpektovania existujúcich oprávnení.
Guardrails, audit, monitoring a human-in-the-loop pre rizikové výstupy.	Používanie neschválených AI nástrojov na interné citlivé dáta.

3.5.1 MVP verzia vs. cieľový stav

Rozsah je rozdelený na prvú použiteľnú verziu a cieľový enterprise stav, aby bolo jasné, čo sa overuje ako prvé a čo je plánované až po validácii rizík.

Oblasť	MVP / pilot	Cieľový stav
Dáta	Vybrané verejné alebo nízko rizikové interné dokumenty s jasným vlastníkom.	Širšia znalostná báza podľa klasifikácie, ACL a schválenia Data Ownera.
Modely	Schválený Azure AI model s obmedzeným kontextom a auditom.	Model router pre cloudový, private alebo lokálny model podľa rizika a kvality.
Nástroje / MCP	Primárne read-only nástroje a vyhľadávanie.	Riadené tool actions s allowlistom, policy checkom a human approval pri rizikových akciách.
Governance	Jednoduchý Go/No-Go proces po PoC a pilote.	Pravidelné review modelov, zdrojov, promptov, nákladov, kvality a incidentov.

3.6 Čo AI riešenie robiť môže a čo nie

3.6.1 AI riešenie môže

- vyhľadávať relevantné interné dokumenty, ku ktorým má používateľ oprávnenie,
- sumarizovať dokumenty, zápisnice, požiadavky a diskusie,
- pripravovať návrhy odpovedí a pracovných podkladov,
- pomáhať s analýzou požiadaviek a identifikáciou nejasností,
- navrhovať user stories, akceptačné kritériá, edge cases a otvorené otázky,
- identifikovať možné dopady, riziká a závislosti,
- porovnávať informácie z viacerých povolených zdrojov,
- označiť neistotu, chýbajúce informácie alebo konfliktné zdroje,
- navrhnuť eskaláciu na človeka alebo zodpovednú rolu, ak výstup nie je dostatočne spoľahlivý.

3.6.2 AI riešenie nesmie

- automaticky rozhodovať za používateľa,
- obchádzať existujúce prístupové práva alebo poskytovať informácie z dokumentov, ku ktorým používateľ nemá oprávnenie,
- vykonávať zmeny v systémoch bez explicitného schválenia a bez kontroly oprávnení,
- vytvárať záväzné právne, bezpečnostné, HR alebo finančné stanoviská bez validácie oprávnenou osobou,
- vydávať neoverené tvrdenia za fakty alebo skrývať neistotu,
- používať citlivé dáta mimo schváleného cloudovom alebo on-premise prostredia,
- rozhodovať o oprávneniach používateľov alebo o tom, kto smie vidieť konkrétne dáta.

3.6.3 Rozlíšenie vhodného a nevhodného použitia AI

Scenár	Použitie AI	Podmienka
Vyhľadanie smernice alebo metodiky	Vhodné	Iba z povolených zdrojov, s citáciou a limitáciami.
Návrh user stories alebo odpovede	Vhodné ako draft	Výstup musí schváliť Product Owner, analytik alebo zodpovedná rola.
Právne, HR, finančné alebo bezpečnostné stanovisko	Nevhodné ako finálne rozhodnutie	Len podklad pre oprávneného experta, nie automatické stanovisko.
Zmena dát alebo akcia v produkčnom systéme	Nevhodné autonómne	Vyžaduje explicitné schválenie, audit a kontrolu oprávnení.
PII-heavy alebo regulované dáta	Obmedzene	Redakcia, lokálny/private režim alebo human review podľa klasifikácie.

4 Návrh architektúry v Azure

Navrhovaná architektúra je Azure-native RAG architektúra s enterprise bezpečnosťou, auditom a human oversight. Riešenie kombinuje aplikačnú orchestration vrstvu, permission-aware retrieval nad internými dokumentmi, modelovú vrstvu Azure OpenAI / Azure AI Foundry, guardrails, monitoring a auditné mechanizmy.

4.1 Logický pohľad

Vrstva	Popis / komponenty
Používateľská vrstva	Microsoft Teams, interný web portál alebo intranetový chat.
Edge a API vrstva	Azure Front Door alebo Application Gateway, Web Application Firewall, Azure API Management.
Identitná vrstva	Microsoft Entra ID, MFA, Conditional Access, skupiny, aplikačné roly a delegated permissions, access packages - JIT access s obnoviteľným prístupom cez MyApps.

Vrstva	Popis / komponenty
Policy enforcement	RBAC
AI orchestration	aplikačná vrstva na Azure Container Apps, AKS alebo App Service.
Retrieval vrstva	Azure AI Search s hybridným a vektorovým vyhľadávaním a ACL pre-filteringom alebo Azure PostgreSQL server s vektorovou databázou.
Dátová vrstva	SharePoint, Confluence, Jira, ServiceNow, Azure DevOps, Blob Storage, Data Lake alebo iné interné zdroje; hybrid access do on-premise cloudu pre externé systémy organizácie.
Modelová vrstva	Azure OpenAI Service alebo Azure AI Foundry Models.
Kontrolná vrstva	AI Input & Context Verifier, AI Output Verifier, groundedness check, scoring agent a human-in-the-loop.
Observabilita	Azure Monitor, Application Insights, Log Analytics, Microsoft Sentinel a auditné úložisko.
Sieťové rozhranie	VPN Gateway alebo VPN Hub s prístupom do VNet pre každú pobočku. Private access point pre komunikáciu medzi systémami. VNet pre AI Assistant systém s prístupom k interným a externým dátam organizácie.
External/on-premise access	Azure Site-to-Site do VPN Hub/Gateway, P2S access pre external users.

4.2 Hlavné architektonické komponenty

4.2.1 Používateľské rozhranie

Používateľské rozhranie môže byť realizované ako Microsoft Teams aplikácia, interný web portál alebo chatbot integrovaný do intranetu. V prípade use casu pre verejne dostupné zdroje je vhodné zvážiť použitie existujúcich enterprise riešení pre AI asistentov, ktoré garantujú zachovanie dát v privátnej zóne organizácie. Rozhranie musí zobrazovať odpoveď, použité zdroje, upozornenia na neistotu, možnosť spätnej väzby a možnosť eskalácie na človeka.

4.2.2 API a bezpečnostná vstupná vrstva

Azure API Management bude slúžiť ako centrálna API vrstva pre publikovanie interných endpointov, throttling, rate limiting, validáciu requestov, routing, logging a oddelenie interných a externých volaní. Pred API vrstvou môže byť Azure Front Door alebo Application Gateway s Web Application Firewallom.

4.2.3 Autentifikácia a autorizácia

Autentifikácia bude riešená cez Microsoft Entra ID. Riešenie použije Single Sign-On, MFA, Conditional Access, skupiny, aplikačné roly, delegated permissions a On-Behalf-Of flow pre volania downstream systémov v mene používateľa. Autorizácia musí byť vynútená mimo LLM. Pri retrievale a volaní nástrojov sa použije deterministická politika podľa používateľských claims, dokumentových ACL, klasifikácie dát a pravidiel rizikovosti. Pridávanie rolí bude riešené cez Entra ID Access Package a definované policies.

4.2.4 Orchestration vrstva

Orchestration vrstva je aplikačné jadro riešenia. Môže byť nasadená na Azure Container Apps, Azure App Service alebo Azure Kubernetes Service. Bude zodpovedná za spracovanie používateľskej požiadavky, výber workflow, výber modelu, volanie retrieval vrstvy, volanie interných nástrojov, aplikovanie politik, audit a validáciu výstupov.

Komponent	Zodpovednosť / funkcia
Agent Manager	riadi typ úlohy a vhodný workflow.
Context Engineering / RAG Builder	skladá systémový prompt, úlohovú šablónu, používateľský zámer, RAG kontext, zdrojové metadáta, autorizačný kontext, výstupnú schému a bezpečnostné inštrukcie.
Tool Router	povoľuje a volá interné nástroje alebo MCP konektory podľa politiky.
Model Router	vyberá vhodný model podľa citlivosti dát, typu úlohy a požadovanej kvality.
Session Context	spravuje kontext konverzácie bez zbytočného uchovávaní citlivých dát.
Input & Context Verifier	kontroluje používateľský prompt, retrieved chunks, externé zdroje a výstupy nástrojov.
Output Verifier	kontroluje finálny výstup pre koncového používateľa alebo komponent.
Scoring Service	výpočet confidence skóre podľa zoznamu citovaných zdrojov vo výstupe.

4.2.5 Retrieval a znalostná vrstva

Znalostná vrstva bude postavená na Azure AI Search alebo PostgreSQL (vector storage). Index bude obsahovať fulltextové aj vektorové reprezentácie dokumentov, metadáta o zdroji, verzii a vlastníčkovi dokumentu, klasifikáciu dát a ACL informácie. Retrieval musí aplikovať bezpečnostné filtrovanie pred samotným vyhľadávaním.

Metadáta chunku	Účel
chunk_id, document_id	Jednoznačná identifikácia časti dokumentu a jej zdrojového dokumentu.
source_system, source_url	Dohľadateľnosť zdroja a možnosť používateľovi zobraziť originál.
document_version	Rozlíšenie aktuálnych a historických verzií dokumentu.
owner, department	Zodpovednosť za obsah a eskalácia pri otázkach.
classification	Pravidlá pre spracovanie citlivých alebo regulovaných dát.
acl_groups, acl_users	Permission-aware retrieval podľa oprávnení používateľa.

Metadáta chunku	Účel
valid_from, valid_to, retention_policy	Kontrola platnosti a retenčných pravidiel.

4.2.6 Dátová ingestná vrstva - Document Processor

Interné dokumenty budú spracované cez aplikáciu Document Processor. Cieľom je extrahovať text, rozdeliť dokumenty na vhodné chunky, doplniť metadáta, vypočítať embeddings a uložiť výsledky do vector storage.

1. Zber dokumentov z povolených zdrojov. Príklad: SharePoint, Confluence, Jira, ServiceNow, Azure DevOps alebo file share v cloude alebo on-premise.
2. Uloženie originálnych alebo normalizovaných dokumentov do Azure Blob Storage alebo Data Lake Storage
3. Verziovanie dokumentov/dát pre embedding.
4. Chunking, deduplikácia, klasifikácia, DLP kontrola a doplnenie ACL metadát.
5. Výpočet embeddings a vytvorenie fulltextového aj vektorového indexu v Azure AI Search.
6. Pravidelná synchronizácia zmien -> viď Document Processor/notifikácie zmien.
7. Anonymizácia citlivých údajov v normalizovaných dokumentoch a embedding dátach alebo pseudonymizácia podľa typu úlohy.

4.2.7 Modelová vrstva

Modelová vrstva bude realizovaná cez Azure OpenAI Service alebo Azure AI Foundry Models. Výber modelu bude riadený podľa citlivosti dát, typu úlohy, požadovanej kvality výstupu a dostupných bezpečnostných kontrol.

Typ dát	Odporúčaný modelový režim
Verejné alebo nízko rizikové dáta	Schválený Azure AI model s bežnými guardrails.
Interné dôverné dáta	Azure OpenAI / Azure AI Foundry s private networkingom, auditom a DLP kontrolou.
Regulované alebo vysoko citlivé dáta	Obmedzený režim, dodatočné schválenie, prípadne private/local model, prípadne použitie lokálneho modelu.
Citlivé dáta, špeciálne dáta, prihlasovacie údaje	Redakcia alebo blokovanie pred odoslaním do modelu.

4.2.8 Guardrails a validácia

Riešenie bude obsahovať ochranné vrstvy pred vstupom do modelu aj po vygenerovaní odpovede. Guardrails nemajú nahrádzať autorizáciu, ale dopĺňať ju o kontrolu obsahu, bezpečnostných rizík, groundedness a kvality odpovede.

- kontrola používateľského promptu
- kontrola retrieved dokumentov, výstupov nástrojov a OCR textu,
- detekcia prompt injection a nepriamych inštrukcií v dokumentoch,
- detekcia PII, secrets a citlivých dát,
- kontrola výstupu, groundedness validácia a claim-to-source kontrola,
- scoring kvality a rizika odpovede, pri scoringu uprednostňovať interné dokumenty pred interných zdrojov a znalostnej bázy.
- human-in-the-loop pre rizikové, nepodložené alebo nízko spoľahlivé výstupy.

Situácia	Reakcia systému
Unsupported claim – bez zdroja, citácie	Odmietnuť tvrdenie, upraviť odpoveď alebo posunúť na human review.
Prompt injection	Zablokovať, izolovať škodlivé inštrukcie alebo vrátiť bezpečnú odpoveď.
PII alebo secrets	Redigovať, zablokovať alebo eskalovať podľa klasifikácie.
Vysokorizikový nástroj alebo akcia	Vyžadovať explicitné schválenie a auditovať rozhodnutie.
Nízke skóre kvality	Zobraziť limitácie alebo posunúť výstup na človeka.

4.2.9 Evaluačný model kvality odpovedí a Go/No-Go a základ produkčného reportingu

Pred pilotom a produkciou sa má vytvoriť referenčný dataset otázok s očakávanými odpoveďami, povolenými zdrojmi a hodnotením reviewerom. Pri zmene modelu, promptu alebo indexu sa testy opakujú ako regresný test.

Oblasť	Metrika	Príklad Go/No-Go kritéria
Správnosť odpovedí	Podiel odpovedí schválených reviewerom	>= 85 % pri MVP scenároch.
Citácie a zdroje	Odpovede so správnou citáciou a podporou v zdroji	>= 90 % odpovedí so správnym source coverage.
Halucinácie	Unsupported alebo partial claims	< 5 % kritických nepodložených tvrdení.
Autorizácia	Neoprávnený retrieval alebo tool call	0 kritických incidentov.
Ochrana dát	PII/secrets leakage	0 kritických únikov; všetky nálezy redigované alebo blokové.
Prevádzka	Latencia, chybovosť, náklady	SLA a budget threshold potvrdené počas pilotu.

4.2.10 Audit, monitoring a observability

Auditná vrstva bude zbierať udalosti zo všetkých dôležitých komponentov: API Gateway, autentifikácia, autorizácia, orchestrator, retrieval vrstva, modelová vrstva, nástroje a konektory, input verifier, output verifier, scoring agent a human-in-the-loop rozhodnutia.

- user_id, session_id, request_id a correlation_id,
- použitý model a verzia modelovej konfigurácie,
- volané nástroje a interné API,
- identifikátory použitých dokumentov a chunkov,
- autorizačné rozhodnutie a dôvod povolenia alebo zamietnutia,
- výsledky validácie vstupu a výstupu,

- scoring kvality a rizika,
- human-in-the-loop rozhodnutia,
- Session chat user/system messages.

4.2.11 Runtime flow a dátové toky

Pre lepšiu čitateľnosť je vhodné explicitne oddeliť runtime flow používateľskej otázky od document processor ingestion flow dokumentov. Architektúra tak jasne ukazuje, kde sa vynucuje autorizácia, kde sa vykonáva retrieval a kde sa kontroluje výstup modelu.

4.2.11.1 AI Assistant aplikačný flow

Krok	Popis	Kontrola / výstup
1. Používateľská otázka	Používateľ zadá otázku cez Teams, interný portál alebo chatové rozhranie.	Request ID, používateľský kontext, typ požiadavky.
2. API a autentifikácia	Požiadavka prejde cez API Gateway / WAF a používateľ je overený cez Microsoft Entra ID.	SSO, MFA, Conditional Access, validný token.
3. Autorizácia a policy check	Orchestrator vyhodnotí claims, roly, skupiny, dátovú klasifikáciu a povolené nástroje.	Deterministické rozhodnutie mimo LLM.
4. Input & Context Verifier	Skontroluje prompt, riziko prompt injection, citlivé údaje a prípadné nebezpečné inštrukcie.	Blokovanie, redakcia alebo pokračovanie workflow.
5. Permission-aware retrieval / tool call	RAG vyhľadá iba dokumenty, ktoré používateľ smie vidieť, alebo zavolá povolený interný tool.	ACL pre-filtering, audit použitých zdrojov a toolov.
6. Context Engineering / RAG Builder	Zostaví bezpečný modelový kontext zo šablóny, používateľského zámeru, povolených chunkov, metadát a výstupnej schémy.	Minimalizovaný kontext, citácie, pravidiel odpovede.
7. Model Router a modelová odpoveď	Vyberie vhodný model podľa typu úlohy, citlivosti dát, ceny a kvality.	Lokálny, Azure OpenAI / Azure AI Foundry alebo schválený externý model.
8. Output Verifier a scoring	Overí tvrdenia voči zdrojom, groundedness, PII leakage, kvalitu a rizikovosť odpovede.	Supported / partial / unsupported claims, quality & risk score.
9. Human-in-the-loop alebo finálna odpoveď	Pri nízkej istote alebo vysokom riziku ide výstup na človeka, inak sa vráti odpoveď so zdrojmi.	Auditovateľný výsledok, spätná väzba používateľa.

4.2.11.2 Document Processor - ingestný flow dokumentov

Krok	Popis	Výstup
1. Zber dokumentov	Document Processor číta dokumenty iba zo schválených zdrojov ako SharePoint, Confluence, Jira, ServiceNow, Azure DevOps alebo Blob/Data Lake.	Zoznam spracovaných dokumentov a zdrojových systémov.
2. Normalizácia a klasifikácia	Text sa extrahuje, očistí, klasifikuje podľa citlivosti, doplní o vlastníka, verziu, platnosť a ACL.	Normalizovaný dokument s metadátami.
3. Bezpečnostná kontrola	Prebehne DLP kontrola, detekcia PII/secrets, kontrola prompt poisoning a validácia dôveryhodnosti zdroja.	Redigovaný alebo schválený obsah pre indexáciu.
4. Chunking a embedding	Dokument sa rozdelí na chunky, vypočítajú sa embeddings a pripraví sa fulltextový index.	Chunky s embeddingmi a bezpečnostnými metadátami.
5. Indexácia	Dáta sa uložia do Azure AI Search alebo PostgreSQL/pgvector podľa zvolenej technológie.	Permission-aware index použiteľný pre RAG.
6. Synchronizácia zmien	Zmeny dokumentov spúšťajú reindexing alebo inkrementálnu aktualizáciu indexu.	Aktuálna znalostná báza s históriou verzií.

4.2.12 Deployment

Uloženie zdrojového kódu, skriptov, konfiguračných súborov a projektových dát bude zabezpečené v prostredí **GitHub** alebo **Azure DevOps**. Nasadenie systému bude realizované pomocou **Bicep** a princípov **Infrastructure as Code**, pričom vývoj infraštruktúry bude prebiehať kontinuálne spolu s vývojom samotného systému. Cieľom je minimalizovať počet manuálnych zásahov pri vytváraní prostredí a pri správe prístupov k zabezpečeným dátam, credentials a oprávneniam.

Riešenie bude nasadzované do oddelených prostredí **DEV**, **TEST**, **UAT** a **PROD**. Pre každé prostredie bude použitý automatizovaný proces nasadenia infraštruktúry aj aplikačných komponentov. V prostrediach **UAT** a **PROD** sa odporúča použiť **feature flags** v kombinácii s **blue-green** alebo **canary deploymentom**, aby bolo možné nové funkcionality sprístupniť najskôr obmedzenej skupine používateľov a následne ich postupne rozšíriť na širšiu používateľskú základňu.

4.2.13 Disaster Recovery Plan

Komponent	DR opatrenie
Frontend / Teams bot	opätovné nasadenie z CI/CD
API Management	export konfigurácie, IaC redeploy
Orchestration aplikácia	container image v Azure Container Registry
Azure AI Search	pravidelný rebuild indexu zo storage a zdrojových dokumentov
Postgres	Backup a recovery, setup v inom regióne.
Blob/Data Lake	geo-redundantné úložisko alebo pravidelná replikácia

Komponent	DR opatrenie
Key Vault	backup secrets/certifikátov, soft delete, purge protection
Log Analytics	retention policy, export kritických auditov
Azure OpenAI	sekundárny model deployment v inom regióne, ak je dostupný
Prompt templates	verzované v Git repozitári
Konfigurácie	uložené v App Configuration / Git / IaC

4.2.14 RTO a RPO

Pre prvú produkčnú verziu navrhujem cieľové hodnoty: RTO 4–8 hodín pre aplikačnú vrstvu a orchestration služby, RPO do 24 hodín pre znalostné indexy, pretože Azure AI Search index je možné obnoviť zo zdrojových dokumentov a storage. Pre auditné logy, konfiguračné dáta, Key Vault a kritické metadáta navrhujem prísnejšie RPO do 1 hodiny podľa dostupnej replikácie a backup politiky. Presné hodnoty musia byť potvrdené počas MVP podľa kritickosti služby, požadovaného SLA a interných prevádzkových pravidiel organizácie.

4.2.15 Cost

Náklady odporúčam riadiť fázovo. PoC má používať obmedzený počet dokumentov, limitované modelové volania a malé testovacie prostredie. MVP má mať samostatné DEV/TEST/UAT prostredia s nastaveným rozpočtom, alertmi a rate limitingom. Produkčné náklady budú závisieť najmä od počtu používateľov, objemu dokumentov, frekvencie reindexingu, veľkosti modelov, počtu tokenov a požiadaviek na vysokú dostupnosť. Pre produkciu odporúčam zaviesť FinOps kontrolu: mesačný budget, cost alerts, samostatné tagovanie AI komponentov, monitoring spotreby tokenov, vyhodnocovanie cache/reuse odpovedí a pravidelnú optimalizáciu model routingu.

4.3 Zhrnutie návrhu

Navrhované riešenie je bezpečný interný AI asistent v Azure, ktorý kombinuje RAG, Azure AI Search alebo PostgreSQL, Azure OpenAI / Azure AI Foundry, Microsoft Entra ID, policy enforcement, guardrails, audit a human-in-the-loop. Riešenie rešpektuje požiadavku, že AI nemá rozhodovať za používateľa, ale má poskytovať overiteľné návrhy, odporúčania a pracovné podklady.

Priložené grafické vysvetlenie v Prilohe A a Prilohe B

5 Biznis a architektonické princípy

Riešenie by malo byť navrhnuté a prevádzkované podľa princípov, ktoré kombinujú bezpečnosť, ochranu dát, transparentnosť, auditovateľnosť a praktickú použiteľnosť pre biznis aj IT tímy.

Princíp	Čo znamená pre riešenie	Praktická kontrola
Security by design	Bezpečnosť je súčasťou návrhu od začiatku. AI asistent nesmie obchádzať existujúce pravidlá prístupu k dátam, aplikáciám ani procesom.	Security review, threat modeling, WAF/API gateway, private networking, pravidelné kontroly konfigurácie.
Least privilege a deterministická autorizácia	Používateľ dostane iba informácie a funkcie, na ktoré má oprávnenie. Autorizácia sa vynucuje mimo LLM a nepoužíva sa generický privilegovaný účet.	Entra ID skupiny/roly, delegated access, ACL pre-filtering, policy enforcement pred retrievalom a tool execution.
Privacy by design	Do modelu sa posielajú iba nevyhnutný kontext. Citlivé dáta, PII, secrets a regulované údaje sa redigujú, blokujú alebo spracujú iba v schválenom prostredí.	DLP, redakcia PII/secrets, data minimization, retenčné politiky, audit logov po redakcii.
Transparentnosť odpovedí	Používateľ musí vidieť, že AI výstup je návrh, nie záväzná rozhodnutie. Odpoveď má uvádzať zdroje, obmedzenia a neistotu.	Povinné citácie zdrojov, označenie odpovede ako návrh, zobrazenie limitácií a odporúčanie na manuálne overenie.
Explainability a groundedness	Pri odpovediach k procesom, smerniciam a požiadavkám musí byť jasné, ktoré tvrdenia sú podložené zdrojmi a ktoré sú odvodením.	Claim-to-source kontrola, groundedness score, output verifier, pravidlo „bez zdroja neuvádzať ako fakt“.
Human oversight	AI asistent nesmie robiť záväzné rozhodnutia. Pri nízkej istote, vysokom riziku alebo dopade na proces sa zapája zodpovedná osoba.	Human-in-the-loop workflow, schvaľovanie rizikových výstupov, eskalácia na vlastníka procesu alebo dát.
Kvalita odpovedí a merateľnosť	Kvalita sa nehodnotí iba subjektívne. Musia byť definované metriky kvality, presnosti, úplnosti, zdrojového pokrytia a spokojnosti používateľov.	Evaluačný dataset, referenčné otázky, groundedness, source coverage, feedback používateľov, trend halucinácií.
Auditovateľnosť a traceability	Každá významná interakcia musí byť spätne dohľadateľná vrátane zdrojov, modelu, toolov, politik a rozhodnutí human-in-the-loop.	Correlation ID, audit udalostí, nemenné logy, SIEM integrácia, oddelená retenčná politika.
Vendor independence a model routing	Riešenie nemá byť závislé od jedného modelu alebo providera. Model sa vyberá podľa use casu, kvality, ceny a citlivosti dát.	Model router, abstrakcia modelovej vrstvy, možnosť použiť cloudový, lokálny alebo špecializovaný model.
Governance	Nové zdroje, nástroje, AI modely a dátové toky musia mať jasný proces schvaľovania a vlastníctva.	AI governance board, Data Owner approval, change management, prevádzkové dashboards a pravidelné review.

6 Riziká a mitigácie

Riziká sú nižšie oddelené od navrhovaných riešení, aby bolo jasné, čo je problém, aký môže mať dopad a aké kontrolné mechanizmy ho majú znižovať.

Oblasť rizika	Popis rizika	Možný dopad	Mitigácia / kontrolný mechanizmus
Technické riziká	Nesprávne alebo neúplné odpovede modelu, halucinácie, slabá kvalita sumarizácie, neaktuálne dáta v znalostnej báze, zlyhanie RAG vyhľadávania alebo nesprávne zvolený model.	Nízka dôvera používateľov, nesprávne pracovné podklady, potreba opakovaných manuálnych kontrol.	RAG s citáciami, output verifier, AI scoring agent, referenčné testovacie otázky, monitoring kvality odpovedí, fallback scenáre a pravidelný reindexing znalostnej bázy.
Bezpečnostné riziká	Neoprávnený prístup k dokumentom, únik citlivých informácií, prompt injection, zneužitie MCP nástrojov alebo použitie príliš privilegovaného servisného účtu.	Data leakage, porušenie interných politík, bezpečnostný incident alebo neautorizované vykonanie akcie.	Autorizácia mimo LLM, permission-aware retrieval s ACL pre-filteringom, RBAC/ABAC policy layer, DLP, redakcia PII/secrets, tool allowlist, audit a human approval pri rizikových akciách.
Dátové riziká	Nekvalitné, duplicitné, zastarané alebo nekonzistentné dokumenty; embedding index môže obsahovať nesprávne alebo neautorizované dáta; riziko otrávenia znalostnej bázy. Zmena dát, dokumentov v dôsledku zmeny legislatívy.	Neaktuálne alebo nesprávne odpovede, únik informácií cez retrieval, strata dôvery v znalostnú bázu.	Data classification, metadáta pre dokumenty a chunky, vlastníctvo zdrojov, verzionovanie, schvaľovanie zdrojov, immutable retrieval logy, validácia a pravidelná kurácia znalostnej bázy. Sledovanie systémového driftu.
Infraštruktúrne riziká	Nedostupnosť AI služieb alebo externého providera, vysoká latencia, neočakávané náklady pri škálovaní, slabý support model alebo problémy pri incidentoch.	Výpadok služby, zhoršená používateľská skúsenosť, rast nákladov alebo pomalé riešenie incidentov.	Hybridná architektúra, model routing, SLA monitoring, rate limiting, kapacitné plánovanie, fallback na obmedzený režim alebo lokálny model, incident management a prevádzkové dashboards.
Organizačné riziká	Používatelia môžu výstupom AI príliš dôverovať, obchádzať štandardné procesy alebo používať asistenta na nevhodné účely.	Nesprávne rozhodnutia, oslabenie existujúcich schvaľovacích procesov alebo nízka adopcia riešenia.	Jasné pravidlá používania, školenia, označenie AI výstupov ako návrhov, human-in-the-loop pre dôležité výstupy, spätná väzba, governance board a pravidelné hodnotenie prínosu aj rizík.
Regulačné a compliance riziká	Spracovanie osobných údajov, citlivých interných informácií alebo regulovaných dát mimo povoleného prostredia; nedostatočný audit alebo nesúlad s internými politikami.	Porušenie GDPR, interných pravidiel alebo auditných požiadaviek; riziko sankcií a reputačnej škody.	Data minimization, model routing podľa klasifikácie dát, blokovanie alebo redakcia citlivých údajov, audit trail, retenčné pravidlá, právne a bezpečnostné posúdenie providerov, DPIA/AI risk assessment pri relevantných use cases.

7 Governance a spolupráca

Governance má byť nastavená jednoducho, ale dostatočne formálne na to, aby bolo jasné, kto vlastní use case, kto schvaľuje dátové zdroje, kto zodpovedá za bezpečnosť a kto rozhoduje o produkčnom nasadení. Pre prvé fázy odporúčam plochý agilný model s jedným cross-funkčným tímom a pravidelným architektonicko-bezpečnostným review.

Rola / tím	Hlavná zodpovednosť
Product Owner	Definuje biznis hodnotu, prioritu use casov, akceptačné kritériá a vyhodnocuje adopciu riešenia.
Architect	Zodpovedá za cieľovú architektúru, integračné vzory, model routing, RAG architektúru a technické rozhodnutia.
Business Owner / Key User	Validuje, či odpovede asistenta dávajú zmysel v reálnom procese, a poskytuje referenčné otázky a spätnú väzbu.
Data Owner	Schvaľuje použitie dátového zdroja, vlastní kvalitu, aktuálnosť, klasifikáciu a prístupové pravidlá k dokumentom.
Security / Compliance	Posudzuje prístup k dátam, DLP, audit, retenčné pravidlá, prompt injection riziká, GDPR a bezpečnostné výnimky.
Development tím	Implementuje frontend, orchestrator, konektory, guardrails, testy, CI/CD a integrácie.
Platform / DevOps / Infra tím	Prevádzkuje Azure infraštruktúru, networking, monitoring, secrets management, deployment a incident proces.
System Governance tím	Schvaľuje produkčné použitie, výnimky, nové vysokorizikové use cases, nové modely a zásadné zmeny dátových tokov.

7.1 Proces riadenia zmien a schvaľovania

Krok	Popis	Výstup
1. Návrh use casu	Biznis alebo tím navrhne nový use case, očakávanú hodnotu, cieľových používateľov a typ dát.	Use case karta s vlastníkom a prioritou.
2. Predbežné posúdenie rizika	AI Architect, Security a Data Owner posúdia citlivosť dát, oprávnenia, typ modelu, tool access a potrebu human-in-the-loop.	Risk classification a odporúčaný model spracovania.
3. Backlog a implementácia	Product Owner zaradí use case do backlogu a development tím ho implementuje v agilných iteráciách.	User stories, acceptance criteria, testovacie scenáre.
4. Validácia kvality	Key users testujú odpovede na referenčných otázkach, kontroluje sa groundedness, citácie, halucinácie a použiteľnosť.	Evaluačný report a zoznam zistení.
5. Security a compliance review	Overí sa autorizácia, audit, DLP, logovanie, retenčné pravidlá a prístup k dátam.	Schválenie, výnimka alebo požiadavky na úpravu.
6. Go/No-Go	Governance Board alebo poverené role rozhodnú o pilotnom alebo produkčnom nasadení.	Go/No-Go rozhodnutie s podmienkami.
7. Prevádzka a zlepšovanie	Po nasadení sa sledujú metriky kvality, adopcia, incidenty, náklady a spätná väzba používateľov.	Prevádzkový dashboard a zlepšovací backlog.

7.2 Spolupráca tímov

Odporúčany model spolupráce je jeden agilný AI tím s pravidelným zapojením biznisu, architektúry, security a infraštruktúry. Biznis definuje hodnotu a testuje odpovede, vývoj implementuje aplikačné a integračné časti, architektúra drží cieľový dizajn a infraštruktúra zabezpečuje prevádzku, monitoring a bezpečné nasadenie. Pri každom novom dátovom zdroji musí byť jasne určený Data Owner a schválený spôsob autorizácie, indexácie a logovania.

7.3 Prevádzkový model

Oblasť	Odporúčany prístup
Incidenty	Incidenty rozdeliť na aplikačné, dátové, bezpečnostné, modelové a kvalitatívne. Kritické incidenty s rizikom úniku dát eskalovať okamžite na Security a Data Ownera.
Monitoring kvality	Sledovať groundedness, source coverage, počet unsupported claims, používateľský feedback, latency, chybovosť, policy violations a systémový drift výstupov.
Zmeny modelov a promptov	Prompt templates a model konfigurácie verzovať v Git repozitári. Zmeny nasadzovať cez DEV/TEST/UAT/PROD a validovať na referenčnom datasete.
Nové dátové zdroje	Vyžadovať vlastníka zdroja, klasifikáciu dát, spôsob ACL synchronizácie, retenčnú politiku a schválenie Security/Data Owner.
Human-in-the-loop	Použiť pre vysokorizikové, nepodložené alebo nízko skórované odpovede a pri výstupoch s regulačným alebo bezpečnostným dopadom.

8 Porovnanie alternatív riešenia

Pre interného AI asistenta prichádzajú do úvahy tri základné prístupy: cloudové enterprise AI služby, on-premise alebo interné modely a hybridný model. V regulovanom prostredí je najpraktickejšie začať hybridným prístupom, pretože umožňuje kombinovať kvalitu cloudových modelov s prísnejším spracovaním citlivých dát.

Prístup	Výhody	Nevýhody / riziká	Vhodnosť použitia	Odporúčanie
Cloudové AI služby	Rýchly štart, vysoká kvalita modelov, škálovanie, managed služby, dostupné bezpečnostné a monitorovacie nástroje, jednoduchšia integrácia s Azure ekosystémom.	Závislosť od providera, potreba právneho a bezpečnostného posúdenia, náklady podľa spotreby, limity dostupnosti regiónov/modelov, vyššie požiadavky na DLP a model routing.	Vhodné pre verejné, interné nízko až stredne citlivé dáta, sumarizácie, RAG nad schválenými dokumentmi, návrhy odpovedí a analytické výstupy.	Použiť pre PoC/MVP a väčšinu bežných use casov, ak sú splnené požiadavky na private networking, audit, DLP a spracovanie dát v schválenom prostredí.
On-premise / interné modely	Maximálna kontrola nad dátami, možnosť prevádzky v izolovanom prostredí, nižšie riziko odosielania citlivých dát mimo kontrolovanú infraštruktúru, vhodné pre špecifické interné scenáre.	Vyššia technická a prevádzková náročnosť, potreba GPU infraštruktúry, MLOps, patching, monitoring, nižšia kvalita menších modelov, zložitejšie škálovanie a vyššie vstupné náklady.	Vhodné pre vysoko citlivé alebo regulované dáta, PII-heavy scenáre, klasifikáciu, redakciu, lokálnu sumarizáciu a prípady, kde cloudový model nie je povolený.	Nepoužiť ako jediný primárny prístup pre celú V1 bez testovania kvality. Odporúča sa skôr ako doplnkový režim pre citlivé dáta a fallback.
Hybridný prístup	Kombinuje kvalitu cloudových modelov s kontrolou nad citlivými dátami, umožňuje model routing podľa klasifikácie dát, znižuje lock-in, podporuje fallback scenáre a postupné zavádzanie.	Vyššia architektonická komplexita, potreba jasných politik, robustného auditovania, model routingu, DLP a jednotného orchestration layeru.	Najvhodnejší pre enterprise organizáciu s rôznou citlivosťou dát, viacerými zdrojmi, RAG scenármi a potrebou rozširovania use casov.	Odporúčany cieľový prístup. V1 môže začať cloud-first pre menej citlivé scenáre, ale architektúra má byť pripravená na lokálny/private model pre citlivé dáta.

8.1 Odporúčané rozhodnutie

Pre prvú verziu odporúčam hybridnú architektúru s Azure-native základom. Bežné dokumentové Q&A, sumarizácie a príprava analytických podkladov môžu bežať cez schválené Azure AI služby s private networkingom, auditom a DLP. Citlivé dáta, špeciálne kategórie údajov, secrets alebo vysokorizikové tool actions majú byť redigované, blokovanie, smerované do obmedzeného režimu alebo spracované lokálnym/private modelom. Rozhodovanie o modeli musí byť explicitné cez Model Routing Policy, nie implicitné v prompte.

8.2 Otvorené otázky

Čo ešte nevieme na 100 % a čo musíme overiť počas discovery, PoC alebo MVP.

	Prečo je dôležitá	Ako overiť
Kvalita a vlastníctvo dokumentov	RAG bude poskytovať kvalitné odpovede iba pri aktuálnych a dôveryhodných zdrojoch.	Discovery audit zdrojov, Data Owner approval, test duplicit a aktuálnosti.
Dostupnosť ACL na úrovni zdrojov a chunkov	Bez permission-aware retrievalu hrozí únik informácií.	Technický spike s vybraným zdrojom a test neoprávneného prístupu.
Kvalita výstupov pre analytické use cases	User stories a dopadové analýzy musia byť použiteľné pre reálny tím.	Evaluálny dataset, key-user review, porovnanie s referenčnými odpoveďami.
Použitie lokálnych, cloudových a externých modelov	Cloudové modely môžu mať vyššiu kvalitu reasoning výstupov a rýchlejší štart. Lokálne/private modely dávajú väčšiu kontrolu nad dátami, ale môžu mať vyššie prevádzkové náklady a nižšiu kvalitu.	Porovnať kvalitu výstupov na referenčnom datasete, otestovať DLP, model routing, latenciu, náklady a spracovanie citlivých dát.
Náklady a latencia pri adopcii	Pri vyššom počte používateľov môžu rásť tokeny a časy odpovede.	Pilotné meranie tokenov, cache stratégia, rate limiting a FinOps dashboard.
Použitie PostgreSQL/pgvector ako jedinej vektorovej databázy vs. hybridné vyhľadávanie	PostgreSQL/pgvector je jednoduchší a dáva dobrú kontrolu nad dátami a metaúdátami. Azure AI Search alebo hybridné vyhľadávanie môže byť vhodnejšie pre enterprise fulltext, semantic search, ranking, synonymá, filtre a škálovanie.	Otestovať kvalitu retrievalu na referenčných otázkach, ACL pre-filtering, latenciu, škálovanie, DR, náklady, správu indexov a kvalitu fulltextového/semantickeho vyhľadávania.

8.3 Model routing – kritériá výberu modelového režimu

Kritérium	Cloudový režim	Lokálny/private režim	Hybridné pravidlo
Citlivosť dát	Verejné a interné nízko/stredne citlivé dáta po schválení.	Vysoko citlivé, regulované alebo PII-heavy dáta.	Model router rozhoduje podľa klasifikácie a DLP výsledku.
Kvalita reasoning výstupu	Vhodný pre komplexné analýzy, user stories, sumarizácie a vysvetlenia.	Vhodný, ak lokálny model dosahuje požadovanú kvalitu v testoch.	Komplexné úlohy smerovať na silnejší model, citlivý kontext minimalizovať alebo redigovať.
Náklady	Pay-as-you-go, nutné sledovať tokeny a limity.	Vyššie fixné náklady na infraštruktúru a prevádzku.	Optimalizovať cez cache, model routing a oddelenie ľahkých/ťažkých úloh.

Kritérium	Cloudový režim	Lokálny/private režim	Hybridné pravidlo
Prevádzka	Jednoduchšia managed prevádzka.	Väčšia zodpovednosť organizácie za MLOps a infraštruktúru.	Začať managed službami a lokálny režim dopĺňať podľa rizika.
Vendor independence	Vyššie riziko lock-in.	Vyššia kontrola, ale vyššia zložitosť.	Abstrakcia modelovej vrstvy a jednotný orchestrator.

9 Roadmapa zavedenia riešenia

Roadmapa zavedenia interného AI asistenta by mala prebiehať postupne, aby sa minimalizovalo bezpečnostné, dátové a prevádzkové riziko. Cieľom nie je nasadiť celé riešenie naraz, ale overiť hodnotu, kvalitu odpovedí, bezpečnostné kontroly, integračné body a pripravenosť organizácie na prevádzku AI riešenia.


Fáza	Cieľ	Hlavný výstup
1. Discovery	Zadefinovať use cases, dáta, riziká a architektúru	Schválený scope a cieľová architektúra
2. Proof of Concept	Overiť RAG, kvalitu odpovedí a bezpečnosť	Funkčný PoC a odporúčanie pre MVP
3. MVP	Vytvoriť prvú použiteľnú verziu asistenta	MVP s auditom, oprávneniami a monitoringom
4. Pilot	Otestovať riešenie na reálnych tímoch	Vyhodnotenie pilotu a Go/No-Go
5. Produkčné nasadenie	Nasadiť riešenie ako enterprise službu	Produkčný AI asistent so SLA a podporou
6. Rozvoj a škálovanie	Rozširovať use cases, dáta a integrácie	Nové funkcionality, optimalizácia a škálovanie

10 Záver

Pred produkciou by bolo nutné overiť agentickú časť riešenia, ktorá má prístup k osobným údajom a citlivým dátam. Ide o najrizikovejšiu časť architektúry, pretože môže kombinovať interné dáta, oprávnenia používateľa, generatívne výstupy a volanie nástrojov. Bude potrebné overiť prístup k RAG a dokumentom, data loss protection cez anonymizáciu alebo pseudonymizáciu, zamerať sa na ochranu pred AI útokmi, prompt poisoning, RAG dokument prompt poisoning, minimalizovaním halucinácií, zabezpečiť auditovateľnosť a vysvetliteľnosť správania systému.

11 Príloha A – Azure Hybrid Solution Design

Azure Internal AI Assistant - Infrastructure (v1)



12 Príloha B – Doplnkový Component diagram

AI Assistant Internal systems (v1)

